

### 作业三：2D MOG

实验目的：用 EM 方法生成二维高斯分布。

实验过程：

高斯混合模型就是假设数据服从高斯混合分布，即数据可以看作是从数个高斯分布中生成出来的。每个 MOG 由 K 个高斯分布组成，每个高斯称为一个 component，这些 component 线性相加组成 MOG 的概率密度函数，即：

$$\begin{aligned} p(x) &= \sum_{k=1}^K p(k)p(x|k) \\ &= \sum_{k=1}^K \pi_k \mathcal{N}(x|\mu_k, \Sigma_k) \end{aligned}$$

D 维高斯分布可以表示为：

$$\mathcal{N}(x|\mu, \Sigma) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \exp\left\{-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\right\}$$

其中， $\mu$  是 D 维的均值向量， $\Sigma$  是 D\*D 的协方差矩阵， $|\Sigma|$  表示  $\Sigma$  的行列式。具体的求解过程分为两个进行：

1. 估计数据点由每个高斯模型生成的概率：对于每个数据  $x_i$  来说，它由第  $k$  个 Component 生成的概率为

$$\gamma(i, k) = \frac{\pi_k \mathcal{N}(x_i|\mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x_i|\mu_j, \Sigma_j)}$$

由于式子里的  $\mu_k$  和  $\Sigma_k$  也是需要我们估计的值，我们采用迭代法，在计算  $\gamma(i, k)$  的时候我们假定  $\mu_k$  和  $\Sigma_k$  均已知，我们将取上一次迭代所得的值（或者初始值）。

#E-step 计算第 i 个数据由第 k 个分布生成的概率

for i in range(datanum):

for k in range(classnum):

postpro = posterior\_probability(x[i], pmu[k], detpsigma[k], invpsigma[k])

gamma[i, k] = pi[k]\*postpro

gamma[i] = gamma[i]/sum(gamma[i])

```
def posterior_probability(x,pmu,detpsigma,invpsigma): #计算  $N(x_i | \mu_k, \Sigma_k)$ 

    D = len(x)

    #-1/2*(x-μ)TΣ-1(x-μ)

    t = -0.5 * dot(dot((x-pmu).T,invpsigma),x-pmu)

    posprob = (2*pi)**(-D/2) * (detpsigma**(-0.5)) * exp(t)

    return posprob
```

2. 估计每个 Component 的参数：现在我们假设上一步中得到的  $\gamma(i, k)$  就是正确的“数据  $x_i$  由 Component  $k$  生成的概率”，亦可以当做该 Component 在生成这个数据上所做的贡献，或者说，我们可以看作  $x_i$  这个值其中有  $\gamma(i, k)x_i$  这部分是由 Component  $k$  所生成的。集中考虑所有的数据点，现在实际上可以看作 Component 生成了  $\gamma(1, k)x_1, \dots, \gamma(N, k)x_N$  这些点。由于每个 Component 都是一个标准的 Gaussian 分布，可以很容易分布求出最大似然所对应的参数值：

$$\mu_k = \frac{1}{N_k} \sum_{i=1}^N \gamma(i, k)x_i$$

$$\Sigma_k = \frac{1}{N_k} \sum_{i=1}^N \gamma(i, k)(x_i - \mu_k)(x_i - \mu_k)^T$$

其中  $N_k = \sum_{i=1}^N \gamma(i, k)$ ，并且  $\pi_k$  也顺理成章地可以估计为  $N_k/N$ 。

```
pi = NK/datanum

for k in range(classnum):

    for i in range(datanum):

        pmu[k] = pmu[k] + gamma[i][k]*x[i]

    pmu[k] = pmu[k]/NK[k]

    for i in range(datanum):

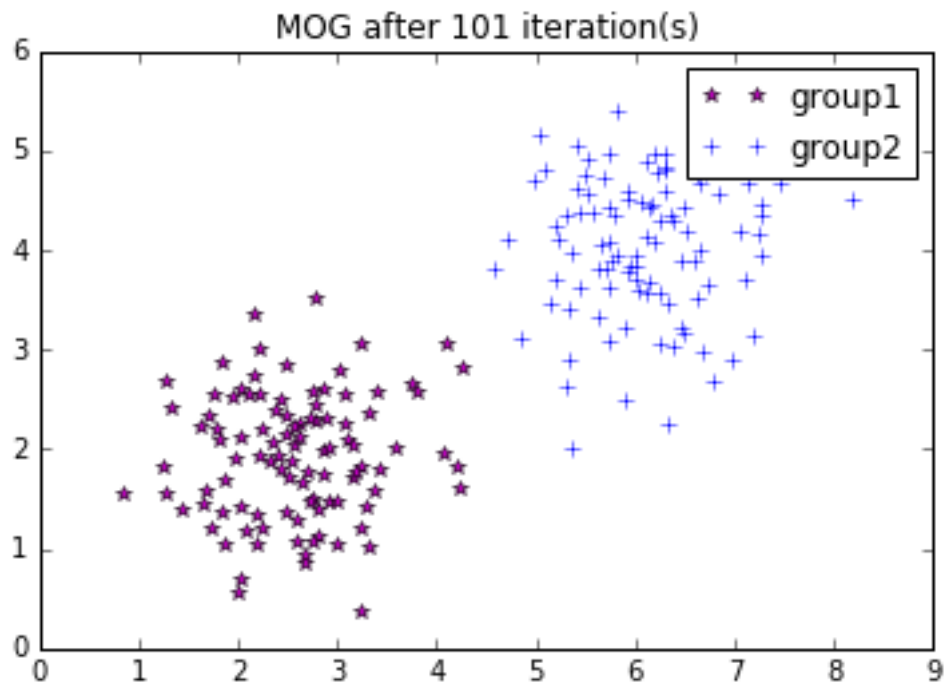
        temp = mat(x[i]-pmu[k])

        psigma[k] = psigma[k] + gamma[i][k]*dot(temp.T,temp)

    psigma[k] = psigma[k]/NK[k]
```

3.重复迭代前面两步，直到似然函数的值收敛为止。在本实验中直接设定其进行100次迭代。

实验结果：



实验小结：EM 算法的基本思路是随机初始化一组参数  $\theta^{(0)}$ ，根据后验概率  $\Pr(Y|X;\theta)$ 来更新  $Y$  的期望  $E(Y)$ ，然后用  $E(Y)$ 代替  $Y$  求出新的模型参数  $\theta^{(1)}$ 。如此迭代直到  $\theta$  趋于稳定。E 步是假设模型参数已知的情况下求隐含变量  $Z$  分别取  $z_1, z_2, \dots$  的期望，亦即  $Z$  分别取  $z_1, z_2, \dots$  的概率。M 步是用最大似然的方法求出模型参数。